Conception d'un système de "tagging" des fichiers avec Rust

Steven Liatti

Projet de bachelor - Prof. Florent Glück

Hepia ITI 3ème année

1er juillet 2018

Résumé Le but de ce projet est de concevoir et développer un "moteur de gestion de tags" pouvant gérer des dizaines de milliers de fichiers et tags associés de manière efficace, en Rust. Le stockage des tags utilisera le mécanisme des "extended attributes" disponibles dans la plupart des systèmes de fichiers modernes. Le moteur d'indexation devra surveiller les fichiers modifiés, créés, ou supprimés afin d'indexer les tags avec un minimum de latence (temps réel). Si le temps le permet, le système développé sera intégré à un environnement desktop choisi (Gnome, KDE, etc.).





Table des matières

1	Intro	oduction	9
	1.1	Motivations	9
	1.2	Buts	9
2	Ana	lyse de l'existant	0
	2.1	Applications utilisateur	0
		2.1.1 TMSU	0
		2.1.2 Tagsistant	0
		2.1.3 TaggedFrog	1
		2.1.4 TagSpaces	1
	2.2	Fonctionnalités disponibles dans l'OS	2
		2.2.1 Windows	2
		2.2.2 macOS	3
3	Arcl	hitecture 1	5
	3.1	Gestion des tags	5
	3.2	Indexation des fichiers et des tags	5
		3.2.1 Indexation avec table de hachage et arbre	5
		3.2.2 Indexation avec un graphe et une table de hachage	9
	3.3	Surveillance du FS	2
	3.4	Recherche par tags	2
4	Ana	lyse technologique 2	3
	4.1	Rust	3
		4.1.1 Installation	3
		4.1.2 Cargo et Crates.io	3
		4.1.3 Généralités	
		4.1.4 Structures de données	8
		4.1.5 Traits et généricité	0
		4.1.6 Énumérations et <i>pattern matching</i>	1
		4.1.7 Collections	2
		4.1.8 Ownership, Borrowing et références	3
		4.1.9 Gestion des erreurs	6
		4.1.10 Tests	8
		4.1.11 Concurrence et threads	
		4.1.12 Divers	
	4.2	Extended attributes	
		4.2.1 Petites manipulations	

	4.3 inotify	41
	4.4 Sockets	43
5	Réalisation	44
	5.1 Tag Manager	44
	5.2 Tag Engine	44
6	Protocole de test	45
	6.1 Benchmarks	45
	6.2 Mesure de performances	45
7	Discussion/résultats	46
8	Conclusion	47
9	Références	48

Table des figures

1	TaggedFrog en utilisation [5]	11
2	TagSpaces en utilisation	12
3	Vue et gestion d'un tag dans le Finder macOS [10]	13
4	Un annuaire représenté comme une table de hachage - [15]	16
5	Représentation sous forme d'arbre d'une hiérarchie de fichiers et répertoires	17

Liste des tables

1	Cas d'utilisation et opérations, première architecture	18
2	Cas d'utilisation et opérations, deuxième architecture	21

Table des listings de code source

1	mdls listant les tags d'un fichier sous macOS [13]	14
2	Installation de Rust sur Linux ou macOS	23
3	Contenu du fichier Cargo.toml	24
4	Exemples de déclarations de variables en Rust	25
5	Quelques types primitifs de Rust	26
6	Exemples de fonctions en Rust	26
7	Exemples de conditions en Rust	27
8	Exemples de boucles en Rust	28
9	Exemples de structures en Rust	29
10	Bloc impl d'une structure en Rust	30
11	Définition d'une enum et son utilisation avec un pattern matching en Rust	31
12	L'énumération Option et son utilisation avec un pattern matching en Rust	32
13	Exemples de déclarations et utilisations d'un vecteur	32
14	Exemples de déclaration et utilisation d'une HashMap	33
15	Portée d'une variable en Rust	34
16	Transfert de l' <i>ownership</i> en Rust	34
17	Transfert de l'ownership vers une fonction en Rust	35
18	Emprunts de variables entre fonctions en Rust	36
19	L'énumération Result et son utilisation avec un pattern matching en Rust	37
20	Ouverture d'un fichier et son traitement en Rust	37
21	Module de test ajouté automatiquement	38
22	Output de df -Th : le disque système, les clés USB et le NFS	39
23	Copie sur clé USB 8 Go, FAT32	40
24	Copie sur clé USB 8 Go, NTFS	40
25	Copie sur clé USB 64 Go, ext4	40
26	Copie sur l'emplacement réseau distant, NFS	40
27	Structure inotify_event - [30]	41

Conventions typographiques

Lors de la rédaction de ce document, les conventions typographique ci-dessous ont été adoptées.

- Tous les mots empruntés à la langue anglaise ont été écrits en italique
- Toute référence à un nom de fichier (ou dossier), un chemin d'accès, une utilisation de paramètre, variable, commande utilisable par l'utilisateur, ou extrait de code source est écrite avec une police d'écriture à chasse fixe.
- Tout extrait de fichier ou de code est écrit selon le format suivant :

```
fn main() {
   println!("Hello, world!");
}
```

• Dans les listings, les lignes précédées d'un "\$" sont exécutées dans un shell.

Structure du document

Remerciements

Acronymes

- **API** Application Programming Interface, Interface de programmation : services offerts par un programme producteur à d'autres programmes consommateurs. 13, 40, 43
- CLI Command Line Interface, Interface en ligne de commande : interface homme-machine en mode texte : l'utilisateur entre des commandes dans un terminal et l'ordinateur répond en exécutant les ordres de l'utilisateur et en affichant le résultat de l'opération. 8
- **FS** *File System*, Système de fichiers : organisation logique des fichiers physiques sur le disque. 9, 10, 15, 18, 19, 21, 38, 40, 41
- GUI Graphical User Interface, Interface graphique : moyen d'intéragir avec un logiciel où les contrôles et objets sont manipulables. S'oppose à l'interface en ligne de commande (CLI). 8
- OS Operating System, Système d'exploitation : couche logicielle entre le matériel d'un ordinateur et les applications utilisateurs. Offre des abstractions pour la gestion des processus, des fichiers et des périphériques entre autres. 9, 11, 32, 38
- **SYSCALL** System call, Appel système : lorsqu'un programme a besoin d'un accès privilégié à certaines parties du système d'exploitation (système de fichier, mémoire, périphériques), il demande au noyau d'exécuter l'opération voulue pour lui. 40, 43
- XATTR Extended Attributes, Attributs étendus : voir section 4.2. 8, 14, 37, 38, 40, 43

1 Introduction

XATTR CLI GUI

- 1.1 Motivations
- 1.2 Buts

[1]

2 Analyse de l'existant

Dans cette section, nous allons analyser les principales solutions existantes, qu'elles soient sous la forme d'applications utilisateur ou intégrées directement dans un OS. Jean-Francois Dockes en dresse également une liste avec avantages et inconvénients sur son site [1].

2.1 Applications utilisateur

2.1.1 TMSU

TMSU [2] est un outil en ligne de commande (CLI) qui permet d'attribuer des tags à des fichiers et d'exécuter des recherches par tags. On commence par initialiser TMSU dans le dossier choisi. Une commande liste les tags associés à un ou plusieurs fichiers et une autre liste les fichiers qui possèdent le ou les tags donnés. TMSU offre la possibilité à l'utilisateur de "monter" un FS virtuel avec FUSE (Filesystem in UserSpacE). L'outil est rapide et efficace, mais il comporte quelques défauts :

- Pas d'interface graphique.
- Dépendance à FUSE pour monter le FS virtuel.
- Stockage des tags dans une base de données SQLite : si la base est perdue, les tags également.

2.1.2 Tagsistant

Tagsistant [3] est autre outil CLI de gestion de tags. Il dépend de FUSE et d'une base de données (SQLite ou MySQL) pour fonctionner. Comme pour TMSU, il faut donner un répertoire à Tagsistant pour son usage interne. À l'intérieur de ce dernier, se trouvent différents répertoires :

```
alias -- Répertoire contenant les requêtes les plus courantes
archive -- Répertoire listant les fichiers
relations -- Répertoire contenant les relations entre les tags et fichiers
stats -- Répertoire contenant des infos sur l'utilisation de Tagsistant
store -- Répertoire où sont gérés les fichiers et ajoutés les tags
tags -- Répertoire de gestion des tags
```

Chaque répertoire a un rôle bien précis. Tout se fait avec le terminal et des commandes usuelles (cp, ls, mkdir, etc.). Dans Tagsistant, un répertoire créé dans le répertoire tags correspond à un tag. On se retrouve finalement avec une arborescence de tags et de fichiers [4]. Bien que cet outil soit performant d'un point de vue de la rapidité d'exécution, il comporte les défauts de TMSU ainsi que des nouveaux :

- Pas d'interface graphique.
- Dépendance à FUSE pour monter le FS virtuel.
- Stockage des tags dans une base de données : si la base est perdue, les tags également.
- Utilisation des différents répertoires peu intuitive.
- Tous les fichiers sont contenus dans un seul répertoire et leur nom est modifié pour les besoins internes de l'application. Obligation de passer par l'application pour accéder aux fichiers.

2.1.3 TaggedFrog

TaggedFrog [5] est un programme disponible sur Windows uniquement et ne partage pas ses sources. Son fonctionnement interne n'est pas documenté. L'interface est agréable, on peut ajouter des fichiers par *Drag & Drop*. L'interface créé au fur et à mesure un "nuage" de tags, comme on peut le retrouver sur certains sites web. On peut exécuter des recherches sur les tags et les fichiers. On peut supposer que TaggedFrog maintient une base de données des tags associés aux fichiers, ce qui ne correspond à nouveau pas à nos besoins.



FIGURE 1 – TaggedFrog en utilisation [5]

2.1.4 TagSpaces

TagSpaces [6] est un programme avec une GUI permettant d'étiqueter ses fichiers avec des tags. L'application est agréable à utiliser, on commence par connecter un emplacement qui fera office de dossier de destination aux fichiers. On peut ajouter ou créer des fichiers depuis l'application. Les fichiers existants ajoutés depuis l'application sont copiés dans le dossier

(cela créé donc un doublon). Sur le panneau de gauche se situe la zone de gestion des tags. TagSpaces ajoute automatiquement certains tags dits "intelligents" aux fichiers nouvellement créés avec l'application (par exemple un tag avec la date de création).

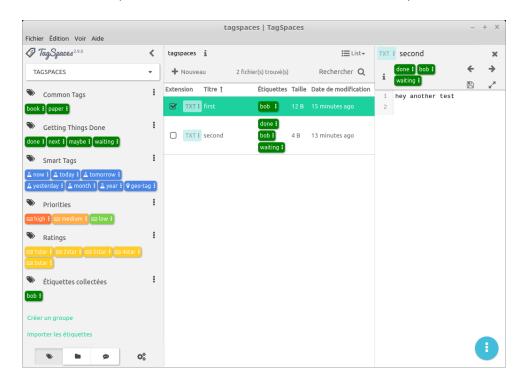


FIGURE 2 - TagSpaces en utilisation

Globalement, l'application est fonctionnelle et *user friendly*. Cependant, deux points noirs sont à déplorer :

- 1. L'application copie les fichiers déjà existants sélectionnés par l'utilisateur, ce qui créé une contrainte supplémentaire dans la gestion de ses fichiers personnels.
- 2. TagSpaces stocke les tags directement dans le nom du fichier, modifiant ainsi son nom [7]. Bien que pratique dans le cas d'une synchronisation à l'aide d'un service cloud, le fichier devient dépendant de TagSpaces. Si l'utilisateur décide de changer son nom sans respecter la nomenclature interne, il risque de perdre les tags associés au fichier.

2.2 Fonctionnalités disponibles dans l'OS

2.2.1 Windows

À partir de Windows Vista, Microsoft a donné la possibilité aux utilisateurs d'ajouter des méta-données aux fichiers; parmi ces méta-données se trouvent les tags. Il existe une fonctionnalité appelée Search Folder qui permet de créer un dossier virtuel contenant le résultat d'une recherche sur les noms de fichiers ou d'autres critères [8]. Depuis Windows 8, l'utilisateur a la possibilité d'ajouter des méta-données à certains types de fichiers (ceux de la suite office

par exemple), dont des tags. Il peut par la suite exécuter des recherches ciblées via recherche de l'explorateur de fichiers Windows du type meta:value [9]. C'est dommage que Windows ne prenne pas en compte davantage de types de fichiers, comme les PDFs ou les fichiers.txt.

2.2.2 macOS

macOS possède son propre système pour étiqueter des fichiers. Il est intégré depuis la version OS X 10.9 Mavericks. Depuis l'explorateur de fichiers, l'utilisateur a la possibilité d'ajouter, modifier, supprimer et rechercher des tags. Les fichiers peuvent avoir plusieurs tags associés. Un code couleur permet de plus facilement se souvenir et visualiser les tags attribués. Dans l'explorateur de fichiers, les tags se retrouvent sur le bas côté, pour y accéder plus rapidement.

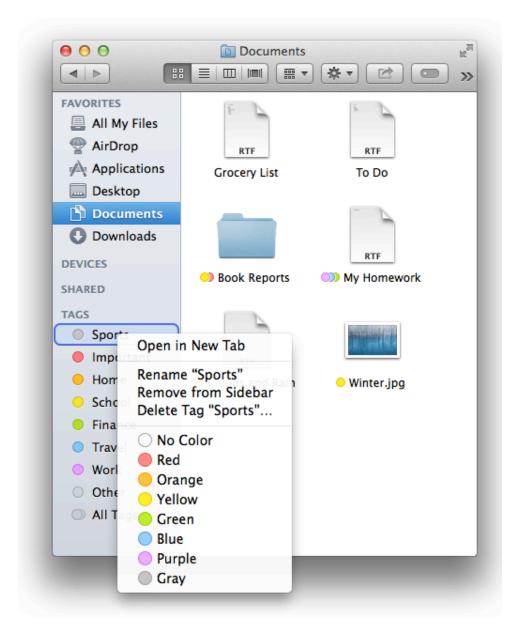


FIGURE 3 – Vue et gestion d'un tag dans le Finder macOS [10]

Lorsque l'on clique sur un tag, une recherche Spotlight est effectuée. Spotlight est le moteur de recherche interne à macOS. Spotlight garde un index des tags, fournissant un accès rapide aux fichiers correspondants [11]. Tous ces tags peuvent se synchroniser sur les différents "iDevices" via iCloud. Finalement, un menu de réglages permet la gestion des tags (affichage, suppression, etc.) [10], [12]. L'implémentation de ce système utilise les extended attributes (voir section 4.2) pour stocker les tags. Les différents tags se trouvent dans l'attribut kMDItemUserTags, listés les uns à la suite des autres. Via le Terminal, à l'aide de la commande mdls, nous pouvons afficher la liste des tags associés à un fichier, nommé "Hello" pour l'exemple :

```
% mdls -name kMDItemUserTags Hello
kMDItemUserTags = (
Green,
Red,
Essential
)
```

Listing 1 – mdls listant les tags d'un fichier sous macOS [13]

Ici, ce fichier "Hello" est étiqueté avec trois tags, "Green", "Red" et "Essential". Le fait que l'indexation est réalisée avec Spotlight implique une réindexation des fichiers dans le cas d'un changement de nom pour un tag donné sous macOS. Le framework système FSEvents donne une solution partielle : c'est une API (utilisée également par Spotlight) qui offre aux applications la possibilité d'être notifiées si un changement a eu lieu sur un dossier (un événement toutes les 30 secondes). FSEvents maintient des logs de ces changements dans des fichiers, les applications peuvent ainsi retrouver l'historique des changements quand elles le souhaitent [14].

3 Architecture

Le système global est composé de quatre entités distinctes, décrites dans les sous-sections suivantes.

3.1 Gestion des tags

La gestion physiques des tags stockés dans les XATTR est une fonctionnalité indépendante du reste du système. Comme vu dans la section 4.2, des outils système existent pour manipuler les XATTR des fichiers. Cependant, pour offrir un plus haut niveau d'abstraction, une cohérence sur le nommage des tags pour l'indexation et plus de confort pour l'utilisateur final, un outil devient nécessaire pour la gestion des tags. Cet outil se présente, sous sa forme de base, comme un programme en ligne de commande. Il doit, au minimum, offrir la possibilité de lire les tags contenus dans les fichiers et ajouter et supprimer les tags donnés en entrée par l'utilisateur. Il devra pouvoir manipuler plusieurs tags et fichiers simultanément. D'un point de vue algorithmique et structures de données, cette partie n'est pas particulièrement ardue.

3.2 Indexation des fichiers et des tags

L'indexation des fichiers et des tags associés est l'un des deux piliers du système. Il faut créer un index des relations entre les tags et les fichiers. Deux architectures ont été imaginées pour l'indexation des tags et des fichiers.

3.2.1 Indexation avec table de hachage et arbre

La première version de l'architecture de l'indexation, comportant deux structures de données, est la suivante :

- 1. Une table de hachage (ou *hashmap*) associant un tag (son nom, sous forme de chaine de caractères) à un ensemble (au sens mathématique) de chemins de fichiers sur le disque.
- 2. Un arbre, correspondant à l'arborescence des fichiers, avec comme noeuds les dossiers, sous-dossiers et fichiers. Le dossier à surveiller représente la racine de l'arbre. Les liens entre les noeuds représentent le contenu d'un répertoire. L'étiquette du noeud contient le nom du fichier ou du répertoire et l'ensemble des tags associés au fichier.





FIGURE 4 – Un annuaire représenté comme une table de hachage - [15]

Une table de hachage est un tableau associatif. Les composantes de l'association sont la "clé", reliée à une ou plusieurs valeurs. Pour insérer, accéder ou supprimer une entrée de la table, il faut calculer le "hash" de la clé, c'est-à-dire son empreinte unique. Sur la figure 4, nous apercevons les clés en bleu, le résultat du hash en rouge et les valeurs associées en vert. Le risque que deux clés ou plus produisent une même empreinte s'appelle une "collision", c'est pour cela qu'une bonne implémentation d'une table de hachage doit non seulement utiliser une bonne fonction de hachage mais aussi une manière de résoudre les collisions. C'est ainsi que les trois opérations ci-dessus peuvent être réalisées, en moyenne, en temps constant (O(1)) et dans le pire des cas (si les collisions s'enchainent) en temps linéaire (O(n)). Dans notre cas, l'utilisation d'une table de hachage pour stocker la relation entre un tag et ses fichiers est efficace lorsque une recherche par tags est demandée. De plus, en associant un ensemble de chemins de fichiers, des opérations ensemblistes (union, intersection) peuvent être réalisées lorsque une recherche impliquant plusieurs tags est effectuée.

L'arbre, au sens informatique, est une représentation de la hiérarchie du FS dans notre cas. Prenons comme exemple la hiérarchie suivante :



__music __kiss.mp3

Elle peut être obtenue grâce à la commande tree sous Linux par exemple. La même représentation sous forme d'un arbre est illustrée sur la figure 5 :

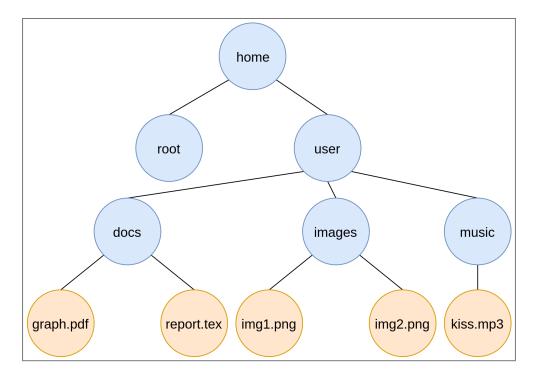


FIGURE 5 – Représentation sous forme d'arbre d'une hiérarchie de fichiers et répertoires

Le noeud "home" représente la racine de l'arbre. Chaque noeud représente soit un fichier (en orange), soit un répertoire (en bleu) sur le disque. Chaque répertoire peut être vu comme un sous-arbre de l'arbre principal. Du point de vue programmatoire, un noeud serait définit, au minimum, comme une structure de données contenant un champ "données" (dans notre cas, le nom du fichier/répertoire et l'ensemble de ses tags) et un champ "enfants", une liste ou un ensemble de pointeurs vers les noeuds enfants. Dans le cas présent, seuls les noeuds répertoires pointent vers des noeuds répertoires ou fichiers enfants, les fichiers n'auraient qu'une liste vide de pointeurs.

La table 1 donne un aperçu des différents cas de figure de l'utilisation du système de fichiers. Pour chaque cas d'utilisation, l'opération correspondante pour les deux structures de données (la table de hachage et l'arbre) est donnée, avec une approximation de la complexité de l'opération en utilisant la notation *Big O*. Les variables suivantes sont définies :

- $c = Operation \ constante$.
- -p = Profondeur de l'arbre.
- t = Nombre de tags.

Cas d'utilisa- tion	Opération hashmap	Opération arbre
Ajout d'un tag à un fi- chier/répertoire	Si tag non présent, ajouter le tag comme clé et ajouter le chemin du fichier à l'ensemble -> $O(c)$	Parcourir l'arbre à la recherche du fichier et ajouter le tag à l'ensemble des tags existants -> $O(p*c)$
Suppression d'un tag d'un fichier/répertoire	Supprimer le fichier de l'ensemble des chemins de fichiers associés au tag -> $O(c)$	Parcourir l'arbre à la recherche du fichier et supprimer le tag de l'ensemble des tags existants -> $O(p * c)$
Ajout d'un fichier	Pour tous les tags du fichier, ajouter au besoin le tag et lui associer le chemin de fichier $\rightarrow O(t*c)$	Parcourir l'arbre à la recherche du répertoire parent du fichier, ajouter le nouveau noeud et l'ensemble de ses tags -> $O(p*c)$
Ajout d'un réper- toire	Opération identique à l'ajout d'un fichier	Parcourir l'arbre à la recherche du répertoire parent, ajouter le nouveau noeud et l'ensemble de ses tags, puis, récursivement, ajouter ses enfants (sous-répertoires et fichiers) -> $\approx O(p^2*c)$
Déplacement /re- nommage d'un fi- chier	Pour tous les tags du fichier, associer le nouveau chemin de fichier -> $O(t * c)$	Parcourir l'arbre à la recherche du parent et changement du lien du noeud avec son parent / simple renommage du nom dans l'étiquette -> $O(p*c)$
Déplacement /renommage d'un répertoire	Pour tous les tags de tous les sous-répertoires et fichiers, associer le nouveau chemin de fichier -> $O(t*p*c)$	Parcourir l'arbre à la recherche du parent et changement du lien du noeud avec son parent / simple renommage du nom dans l'étiquette -> $O(p*c)$
Suppression d'un fichier	Pour tous les tags du fichier, supprimer le chemin de fichier $-> O(t*c)$	Parcourir l'arbre à la recherche du parent et suppression du lien et du noeud $->O(p*c)$
Suppression d'un répertoire	Pour tous les tags de tous les sous-répertoires et fichiers, supprimer le chemin de fichier -> $O(t*p*c)$	Parcourir l'arbre à la recherche du répertoire parent, supprimer le noeud, l'ensemble de ses tags, et récursivement, ses enfants (sous-répertoires et fichiers) -> $\approx O(p^2*c)$

 ${\rm TABLE}\ 1-{\sf Cas}\ {\sf d'utilisation}\ {\sf et}\ {\sf op\'erations},\ {\sf premi\`ere}\ {\sf architecture}$

Cette version a été en partie abandonnée et adaptée pour deux raisons majeures :

- 1. Avoir deux structures de données interdépendantes augmente la complexité des opérations de mise à jour (ajout, déplacement, suppression de fichiers et tags).
- 2. L'implémentation s'est avérée plus difficile que prévue, du fait de certaines contraintes de Rust (voir section 5.2).

3.2.2 Indexation avec un graphe et une table de hachage

Pendant l'implémentation de cette partie du programme (voir section 5.2), une nouvelle architecture a été imaginée. Elle reprend les bases de la précédente, mais simplifie la structure de données. Plutôt que de maintenir deux structures différentes, cette solution propose une structure de données principale, secondée par une structure secondaire, optionnelle, mais néanmoins efficace :

- 1. Un graphe, avec un noeud représentant soit un répertoire, soit un fichier soit un tag. Chaque noeud est une structure de données comportant un nom et type et est identifié de manière unique. Grâce à cet identifiant, les noeuds sont facilement accessibles.
- 2. Une table de hachage, associant le nom d'un tag à son identifiant unique en tant que noeud du graphe.

Les explications suivantes sont appuyées par le cours de Jean-François Hêche, professeur à la heig-vd, sur les "Graphes et Réseaux". La définition d'un graphe non orienté : "Un graphe non orienté est une structure formée d'un ensemble V, dont les éléments sont appelés les sommets ou les noeuds du graphe, et d'un ensemble E, dont les éléments sont appelés les arêtes du graphe, et telle qu'à chaque arête est associée une paire de sommets de V appelés les extrémités de l'arête." (Hêche, page 1, [16]).

La définition d'un graphe orienté : "Un graphe orienté est une structure formée d'un ensemble V, dont les éléments sont appelés les sommets ou les noeuds du graphe, et d'un ensemble E, dont les éléments sont appelés les arcs du graphe, et telle qu'à chaque arc est associé un couple de sommets de V (c.-à-d. un élément de $V \times V$) appelés les extrémités de l'arc." (Hêche, page V, [16]).

Un graphe est donc un ensemble de noeuds reliés par des arêtes ou des arcs, selon si le graphe est orienté ou non. Dans notre cas, l'utilisation d'un graphe n'est pas si éloignée de celle d'un arbre. Par ailleurs, selon la théorie des graphes, "un arbre est un graphe sans cycle et connexe" (Hêche, page 33, [16]). "Sans cycle" signifie qu'un parcours du graphe est possible de telle sorte à ce que le noeud de départ et d'arrivée soient différents. "Connexe" définit un graphe tel que pour chaque paire de noeuds du graphe il existe un chemin les reliant. L'utilisation d'un tel graphe représente fidèlement l'arborescence du FS (on garde le schéma d'un arbre) et simplifie grandement les opérations liées. Le fait d'ajouter les tags comme noeuds du graphe maintient une unique structure de données cohérente et diminue le nombre d'opérations différentes nécessaires lors de la mise à jour du FS. Le parcours de ce graphe se fait en fonction du chemin de fichier donné, en gardant l'identifiant unique du noeud correspondant au répertoire

racine, le parcours se fait de la racine vers le noeud final du chemin de fichier.

La table de hachage utilisée dans cette version peut être vue comme un "cache" d'accès aux noeuds tags. En effet, nous pourrions nous passer de cette table de hachage et lorsqu'un accès à un tag est demandé, rechercher dans tout le graphe le tag en question. Cependant, cette dernière opération devient rapidement conséquente lorsque le graphe comporte de très nombreux noeuds. De plus, elle est accédée bien moins souvent que dans la première version de l'architecture, car elle est mise à jour uniquement lors des opérations sur les tags et non plus sur celles liées seulement aux fichiers et répertoires (opérations potentiellement plus lourdes). Comme pour la sous-section 3.2.1, le tableau 2 donne un aperçu des opérations sur les deux structures de données lorsque le FS est manipulé. Les variables suivantes sont définies :

- $c = Operation \ constante$.
- p = Profondeur du graphe.
- t = Nombre de tags.

Cas d'utilisa- tion	Opération graphe	Opération <i>hashmap</i>
Ajout d'un tag à un fi- chier/répertoire	Parcourir le graphe à la recherche du fichier, si besoin créer le noeud tag, et relier le noeud fichier au noeud tag -> $O(p * c)$	Si non existant, ajouter le nom du tag comme clé et son identifiant dans le graphe comme valeur -> $O(c)$
Suppression d'un tag d'un fichier/répertoire	Parcourir le graphe à la recherche du noeud fichier et supprimer le lien entre noeud tag et fichier. Si le noeud tag n'est relié à aucun autre noeud, le supprimer - $O(p*c)$	Si le noeud tag n'est relié à aucun autre noeud, supprimer l'entrée -> $O(c)$
Ajout d'un fichier	Parcourir le graphe à la recherche du répertoire parent, ajouter le nouveau noeud. Pour les tags existants, lier le nouveau noeud, sinon créer le nouveau noeud tag correspondant -> $O(p*t*c)$	Identique à l'ajout d'un tag à fichier
Ajout d'un réper- toire	Parcourir le graphe à la recherche du répertoire parent, ajouter le nouveau noeud. Pour les tags existants, lier le nouveau noeud, sinon créer le nouveau noeud tag correspondant. Répéter pour la sousarborescence -> $\approx O(p^2*t*c)$	Identique à l'ajout d'un tag à fichier
Déplacement /re- nommage d'un fi- chier/répertoire	Parcourir le graphe à la recherche du parent et changer le lien du noeud avec son parent / simple renommage du nom dans l'étiquette -> $O(p * c)$	Pas d'opération requise
Suppression d'un fichier	Parcourir le graphe à la recherche du noeud fichier et supprimer les liens entre noeuds tags et noeud parent -> $O(p*t*c)$	Pour chaque tag du fi- chier, supprimer le noeud tag s'il n'a plus de liens vers d'autres noeuds -> $O(t*c)$
Suppression d'un répertoire	Parcourir le graphe à la recherche du noeud répertoire et supprimer les liens entre noeuds tags et noeud parent. Répéter pour la sous-arborescence -> \approx $O(p^2*t*c)$	Pour chaque sous répertoire ou sous fichier, opération identique à la suppression d'un fichier

 $\ensuremath{\mathrm{TABLE}}$ 2 – Cas d'utilisation et opérations, deuxième architecture

Nous pouvons constater que les opérations sur la table de hachage sont peu nombreuses et

souvent facultatives, ce qui se traduit par un gain sur le nombre d'opérations totales.

3.3 Surveillance du FS

La surveillance du FS et des tags associés est le deuxième pilier du système. L'indexation initiale est nécessaire, mais il est également nécessaire de surveiller en permanence l'arborescence des fichiers pour garder cet index à jour. Pour y parvenir, nous allons utiliser inotify (voir section 4.3), en surveillant tout particulièrement les événements suivants :

- IN_ATTRIB : changement sur les tags (ajout, suppression, renommage).
- IN_CREATE : création de fichier/répertoire dans le répertoire surveillé. Ajouter une nouvelle surveillance si répertoire.
- IN DELETE : suppression d'un fichier/répertoire dans le répertoire surveillé.
- IN DELETE SELF : suppression du répertoire surveillé.
- IN MOVE SELF : suppression d'un fichier/répertoire dans le répertoire surveillé.
- IN MOVE FROM : déplacement/renommage du répertoire (ancien nom).
- IN MOVE TO: déplacement/renommage du répertoire (nouveau nom).

Un thread s'occupe d'écouter les événements du FS et les inscrire dans un buffer tandis qu'un autre va mettre à jour le graphe pour répercuter les changements survenus en lisant dans ce même buffer (simple pattern producteur-consommateur).

3.4 Recherche par tags

4 Analyse technologique

4.1 Rust

Cette section présente le langage de programmation Rust et certains de ses mécanismes, à travers quelques exemples, qui sont soit absolument nécessaires pour commencer à programmer avec Rust, soit utilisés dans le code de ce projet. Rust est un langage multi paradigmes, fortement typé, compilé et performant. Il peut être utilisé en autres pour de la programmation orientée système, pour créer des programmes CLI ou pour créer des applications web. Fort d'une communauté active, de nombreux packages et modules sont disponibles sur Crates.io [17] et de nombreuses discussions sont présentes sur le reddit [18] dédié. Pour plus de détails, l'excellent livre [19] réalisé par les mainteneurs de Rust saura donner de plus amples et précises informations au lecteur avide de connaissances sur Rust. Un autre livre [20], plus spécialisé, guide le débutant à Rust dans la conception de listes chaînées, car non triviales en Rust de par le fait de ses contraintes

4.1.1 Installation

L'installation de Rust sur Linux et macOS est très simple. Les prérequis sont un compilateur C (certaines librairies Rust en nécessitent un) et l'outil de transfert de données curl. Il suffit ensuite d'ouvrir un terminal et d'entrer la commande suivante :

```
$ curl https://sh.rustup.rs -sSf | sh
```

Listing 2 - Installation de Rust sur Linux ou macOS

Sur Windows, la procédure est un peu plus longue mais tout aussi simple, il faut s'assurer d'avoir les C++ build tools pour Visual Studio 2013 ou supérieur. Rust installe son compilateur, rustc, qui permet de compiler un fichier source (.rs) en fichier exécutable. Nous n'allons cependant pas en parler davantage, la compilation se fera avec le gestionnaire de paquets et de compilation Cargo (voir sous-section 4.1.2). Pour plus de détails, se référer au chapitre 1.1 du book [19]. Le site Are we (I)DE yet? [21] donne un aperçu des éditeurs de texte compatibles avec la chaîne de développement Rust. En ce qui concerne le projet de bachelor présenté ici, tout le code a été écrit avec Visual Studio Code.

4.1.2 Cargo et Crates.io

Cargo est le système de compilation et exécution et le gestionnaire de paquets intégré à Rust. Depuis le terminal, ses commandes principales permettent de créer un nouveau projet (cargo new myproject), de le compiler (cargo build), de l'exécuter (cargo run) ou de générer la documentation associée (cargo doc). Lorsqu'un nouveau projet est créé avec

Cargo, un fichier Cargo.toml est généré (à la manière du fichier package.json avec Node.js et npm) avec le contenu minimal suivant :

```
[package]
name = "myproject"
version = "0.1.0"
authors = ["Firstname Lastname <me@mail.com>"]
[dependencies]
```

Listing 3 - Contenu du fichier Cargo.toml

La section "package" contient les informations sur le projet en lui-même. La section "dependencies" liste les paquets dont dépend notre application, appelés "crates" par la communauté Rust. Des milliers de crates sont disponibles sur Crates.io [17]. D'autres sections peuvent être ajoutées au fichier Cargo.toml pour personnaliser les commandes de compilation, créer des workspaces à partir de plusieurs crates ou ajouter des commandes spécifiques par exemple. Un sous-chapitre (1.3) et un chapitre entier (14) sont dédiés à Cargo dans le livre de Rust [19] et il dispose également d'une documentation complète [22] (comme le book dédié à Rust).

4.1.3 Généralités

Commentaires Tout texte écrit après deux slashs consécutifs ("//") est considéré comme un commentaire en Rust. La syntaxe multiligne qui existe en C par exemple n'est pas prise en compte. En mettant trois slashs consécutifs ("///"), le commentateur indique au compilateur que ce commentaire fait partie de la documentation (qui peut être générée avec Cargo, voir sous-section 4.1.2).

Variables Tout d'abord, pour déclarer une variable en Rust, il faut utiliser le mot-clé let. Une variable est par défaut déclarée immutable, c'est-à-dire qu'elle ne peut pas être modifiée dans la suite du code. Bien que Rust soit un langage fortement typé, son compilateur sait dans la plupart des cas inférer le bon type de la variable, soit en analysant la valeur attribuée, soit en analysant la première utilisation de la variable (arguments d'une fonction, insertion de données dans le cas des collections). Il existe toutefois la possibilité de déclarer explicitement le type de la variable en l'indiquant avant le "=". Pour déclarer une variable mutable, il faut lui ajouter le mot-clé mut avant son nom. Ensuite, les constantes sont déclarées avec le mot-clé const et leur type doit obligatoirement être indiqué. La différence principale entre les constantes et les variables immutables est qu'une constante ne peut être le résultat d'une valeur calculée à l'exécution du programme. Enfin, une variable peut être "masquée" ou "obscurcie" (shadowed) : une nouvelle déclaration avec let et le même nom écrase la précédente valeur et peut être de type différent. Le listing 4 montre quelques cas de déclarations de variables :

```
// Déclaration d'une variable "x", immutable et de type inféré i32
1
   let x = 3;
2
3
   // Déclaration d'une variable "y", mutable et de type inféré bool
   let mut y = true;
5
6
   // Déclaration d'une variable "z", mutable et de type déclaré char
   let mut z : char = 'A';
8
   // La constante PI de type flottant 64 bits
10
   const PI : f64 = 3.1415;
11
12
   // Shadowing. La première déclaration crée une variable nommée "answer"
13
   // de type i32 et de valeur 42, alors que la deuxième écrase la
14
   // précédente variable en lui prenant son nom et est de type String.
15
   let answer = 42;
16
   let answer = answer.to_string();
17
```

Listing 4 – Exemples de déclarations de variables en Rust

Pour plus de détails, se référer au chapitre 3.1 du book [19].

Types Il existe deux familles de types en Rust :

- Les scalaires : nombres entiers, nombres à virgule, booleans et caractères.
- Les composés (deux types primitifs) : les tuples et les tableaux.

Les entiers peuvent être signés ou non signés et sur 8, 16, 32, 64 ou dépendant de l'architecture du processeur (i8, u8, i16, u16, i32, u32, i64, u64, isize, usize). Les nombres à virgule ont deux possibilités, soit sur 32 bits, soit sur 64 bits (f32 ou f64). Le type bool, classique, peut prendre deux valeurs, true ou false. Enfin, dernier type primitif scalaire, chat stocke un caractère Unicode entre simples guillemets. Le premier type primitif composé est le tuple. C'est un regroupement de plusieurs valeurs qui peuvent être de différents types. Lors des déclarations, les noms de variables, les types et les valeurs d'un tuple sont contenues entre parenthèses et séparées par des virgules. Enfin, le type tableau, ou array: classique type regroupant plusieurs valeurs du même type cette fois. Un array a une taille fixe, déterminée à la compilation. La déclaration des valeurs d'un tableau se fait entre crochets "[]". Pour accéder à une valeur du tableau, il faut utiliser la syntaxe array[i] où i est un indice valide du tableau (entre zéro compris et la taille du tableau non compris). Quelques exemples sont donnés dans le listing 5.

```
let myint : i32 = 1234;
1
   let mychar : char = 'a';
2
   let myfloat : f64 = 2.0;
3
   // Déclaration d'un tuple
5
   let tuple : (char, u32, f64) = ('c', 42, 2.8);
6
   // Destructuration du tuple en trois variables distinctes
   let (letter, age, score) = tuple;
8
   // Déclaration d'un tableau
10
   let myarray = ['a', 'b', 'c', 'd', 'e', 'f'];
11
   let x = myarray[4]; // x vaut 'e'
```

Listing 5 – Quelques types primitifs de Rust

Pour plus de détails, se référer au chapitre 3.2 du book [19].

Fonctions Comme en C, tout programme a comme point d'entrée la fonction main(). Une déclaration de fonction commence par le mot-clé fn, est suivi du nom de la fonction, de la liste des éventuels paramètres et des éventuels types de retour. Lorsqu'une fonction a une valeur de retour, la dernière ligne de la fonction qui n'a pas de point-virgule à sa fin est évaluée comme une expression et est retournée. Le mot-clé return existe néanmoins si la fonction doit retourner dans des cas bien précis (dans une condition par exemple). Les variables déclarées dans la fonction ne sont pas accessibles depuis l'extérieur de la fonction. Les arguments de la fonction sont passés par copie par défaut (voir la sous-section 4.1.8 pour plus de détails). Le listing suivant donne l'exemple d'une même fonction, en deux versions plus ou moins courtes. Ces fonctions attendent deux entiers et retournent également un entier.

```
fn x_plus_y_plus_one(x : i32, y : i32) -> i32 {
    let x_plus_y = x + y;
    x_plus_y + 1
}

fn x_plus_y_plus_one_short(x : i32, y : i32) -> i32 {
    x + y + 1
}
```

Listing 6 - Exemples de fonctions en Rust

Pour plus de détails, se référer au chapitre 3.3 du book [19].

Structures de contrôle Comme tout langage de programmation, Rust possède des structures de contrôle pour gérer les consditions et les répétitions (boucles). Il y a le classique if condition { . . . } else if autre_condition { . . . } else { } avec une différence notable par rapport à C : il est possible d'affecter une variable avec un if, comme dans le listing 7. Il n'y a pas de switch . . . case à proprement parler en Rust, nous verrons le match . . . case à la sous-section 4.1.6. En ce qui concerne les boucles, elles sont au nombre de trois : loop (boucle infinie), while (boucle avec condition initiale) et for boucle pour traverser les collections par leurs itérateurs principalement (voir sous-section 4.1.7).

```
// Exemple d'un simple if ... else
   let name = "fred";
   if name == "fred" {
3
        println!("Hello buddy!");
   }
5
   else {
6
        println!("Hello World!");
   }
8
   // Exemple d'affectation d'une variable avec un if. Ici, n vaudra 42
10
   let condition = true;
11
   let n = if condition { 42 }
12
    else { 66 };
13
```

Listing 7 - Exemples de conditions en Rust

```
// Boucle infinie
1
    loop {
2
        println!("Forever");
3
    }
5
    // Boucle avec condition
6
    let mut x = 0;
    while x < 10 {
        println!("{}", x);
        x = x + 1;
10
    }
11
12
    // Parcours d'un tableau
13
    let myarray = [1, 2, 3, 4, 5];
14
    for elem in myarray.iter() {
15
        println!("value : {}", elem);
16
    }
17
```

Listing 8 - Exemples de boucles en Rust

Pour plus de détails, se référer au chapitre 3.5 du book [19].

Organisation des fichiers et modules Un programme écrit en Rust a la possibilité d'être découpé en plusieurs fichiers (autres que main.rs) et modules. Un module peut contenir des déclarations de fonctions, de structures et leurs implémentations (voir section 4.1.4), etc. Le mot-clé pour déclarer un module est mod. Le code à l'intérieur du module est par défaut privé, pour le rendre accessible en dehors du module, le préfixe pub est disponible. Pour utiliser un module au sein d'un autre ou dans main.rs, il faut l'importer avec le mot-clé use. Par défaut, tout module est défini dans le fichier src/lib.rs d'un projet. Si de nombreux modules sont déclarés, il est possible de les mentionner dans src/lib.rs de cette manière : mod mymodule; et de créer un fichier ayant le même nom que le module (dans cet exemple, src/mymodule.rs) contenant le code en question. Une déclaration de module peut en contenir d'autres également, créant ainsi une hiérarchie de modules. Pour plus de détails, se référer au chapitre 7 du book [19].

4.1.4 Structures de données

Comme en C, Rust octroie la possibilité au programmeur de définir ses propres types composés, les struct. La déclaration et l'instanciation d'une structure se font comme en

C avec quelques raccourcis disponibles. Une structure sans noms de champs est également disponible, appelée "tuple struct". Pour accéder aux champs d'une structure, il suffit d'utiliser la notation pointée (player.name).

```
// Structure définissant un personnage dans un jeu vidéo
    struct Player {
2
        name: String,
3
        class: String,
        life: i32,
5
        active: bool
    }
    // Création d'une variable Player
8
    let player_one = Player {
        name: String::from("Groumf"),
10
        class: String::from("Wizard"),
11
        life: 100,
12
        active: true
13
    };
14
15
    // Structure sans noms aux champs
16
    struct Coordinates (f64, f64);
17
    let geneva = Coordinates (46.2016, 6.146);
18
    // Structure vide ()
20
    struct Nil;
21
```

Listing 9 – Exemples de structures en Rust

La particularité des structures, par rapport à C, est qu'il est possible de définir des méthodes rattachées aux structures, à la manière des méthodes en Java, sans pour autant obtenir une classe *stricto sensu* des langages orientés objets, même si le résultat final est très semblable. Pour définir des méthodes à une structure, il est nécessaire de déclarer un bloc de code commençant par le mot-clé impl suivi du nom de la structure et d'accolades. À l'intérieur de ce bloc sont définies des fonctions en relation avec la structure. Dans le listing 10, nous voyons la déclaration de la structure Player et de son implémentation, comportant trois méthodes (avec la syntaxe des fonctions) pour créer un nouveau personnage, qu'il puisse en attaquer un autre et qu'il puisse saluer. La seule différence entre une méthode et une fonction est qu'une méthode qui est appelée sur une variable du type de la structure avec la notation pointée attend le paramètre self comme premier paramètre, obligatoirement. self réfère à la variable ellemême, comme this en Java. Nous pouvons voir que self et les autres paramètres ont une

syntaxe non décrite pour l'instant (& et &mut), la sous-section 4.1.8 donne de plus amples explications.

```
struct Player {
        name: String, class: String, life: i32, force: i32
2
    }
3
4
    impl Player {
5
        fn new(name : String, class : String) -> Player {
            Player { name, class, life : 100, force : 10 }
        }
9
        fn attack(&self, other : &mut Player) {
10
            other.life = other.life - self.force;
11
        }
12
13
        fn say_hi(&self) {
14
            println!("Hi, I'm {}, powerfull {}!", self.name, self.class);
15
        }
16
    }
17
18
    fn main() {
19
        let player_one = Player::new(String::from("Groumf"),
20
            String::from("Wizard"));
21
        let mut player_two = Player::new(String::from("Trabi"),
22
            String::from("Thief"));
23
        player_one.attack(&mut player_two);
24
        player_one.say_hi();
25
    }
```

Listing 10 – Bloc impl d'une structure en Rust

Pour plus de détails, se référer au chapitre 5 du book [19].

4.1.5 Traits et généricité

Pour plus de détails, se référer au chapitre 10 du book [19].

4.1.6 Énumérations et pattern matching

Les énumérations sont une autre manière de concevoir ses propres types. Comme en C, une énumération liste toutes les variantes possibles d'une valeur d'un même type. L'exemple classique d'une énumération sont les jours de la semaine. Sept cas différents, sans évolutions possibles. Les énumérations en Rust prennent tout leur sens en combinaison avec les *pattern matching*: une structure de contrôle ressemblant à un switch . . . case en C mais avec un côté davantage emprunté à la programmation fonctionnelle (on les retrouve d'ailleurs en Scala). Tous les cas possibles d'une énumération doivent être traité avec un match (d'où la clause par défaut _). Le bloc de code à droite de chaque => peut être retourné, comme pour une fonction (voir listing 11).

```
enum Direction {
1
        North, South, East, West
2
   }
3
4
    fn print_direction(direction : Direction) {
5
        match direction {
6
            Direction::North => println!("Go North"),
            Direction::South => println!("Go South"),
            _ => println!("Go East or West") // clause par défaut
        }
    }
11
```

Listing 11 - Définition d'une enum et son utilisation avec un pattern matching en Rust

Rust possède dans la librairie standard une énumération très puissante : Option (recopiée dans le listing 12). Elle remplace le tristement fameux NULL en C ou d'autres langages. Elle supprime simplement d'innombrables bugs souvent rencontrés à cause de NULL. Si une variable existe, elle se retrouve dans le cas Some de l'option, si elle n'existe pas, dans le cas None. Cette énumération est de plus générique (voir sous-section 4.1.5), elle accepte tout type de données.

```
enum Option<T> {
1
        Some(T),
2
        None,
3
   }
5
    fn process(value : Option<u32>) {
6
        match value {
            Some(data) => println!("{}", data),
            None => println!("Error, no data")
        }
10
   }
11
```

Listing 12 – L'énumération Option et son utilisation avec un pattern matching en Rust Pour plus de détails, se référer au chapitre 6 du book [19].

4.1.7 Collections

Cette sous-section décrit les deux collections les plus utilisées en Rust, à savoir les vecteurs (Vec)et les tables de hachage associatives (HashMap). Un vecteur est un tableau qui n'a pas de taille fixe, des éléments peuvent lui être ajoutés ou enlevés. C'est l'équivalent des ArrayList en Java. Un vecteur est générique (voir sous-section 4.1.5), il peut contenir tout type de données, mais un seul type à la fois. De nombreuses méthodes existent pour manipuler un vecteur, que ce soit pour lui ajouter ou enlever des éléments ou pour le convertir vers d'autre formes. Une macro, vec! est disponible pour rapidement créer un vecteur (éléments séparés par des virgules entre "[]"). Le listing 13 donne quelques exemples :

```
// Déclaration d'un vecteur avec new, puis avec la macro
   let v: Vec<char> = Vec::new();
2
   let mut v = vec!['a', 'b', 'c'];
3
   // Ajout d'un élément au vecteur
4
   v.push('d');
5
   // Accès au deuxième élément du vecteur, de deux manière différentes
   let second: &char = &v[1];
   let second: Option<&char> = v.get(1);
   // Parcours (immutable) du vecteur avec la syntaxe for .. in ..
9
   for i in &v {
10
        println!("{}", i);
11
12
```

Listing 13 – Exemples de déclarations et utilisations d'un vecteur

Une HashMap est une table de hachage associative, tel qu'il en existe en Java. Elle est, comme le vecteur, générique (voir sous-section 4.1.5), elle accepte tout type de données. C'est une structure de données efficace pour accéder rapidement à une information. Le listing 14 donne quelques exemples :

```
// Déclaration d'une hashmap avec new
1
   let h: HashMap<char, u32> = HashMap::new();
2
   // Ajout d'une paire clé-valeur à la hashmap
3
   h.insert('a', 97);
4
   // Accès à la valeur associée à la clé 'a', retourne une Option
   let a: Option<&u32> = h.get('a');
6
   // Parcours (immutable) de la hashmap avec la syntaxe for .. in ..
   for (key, value) in &h {
       println!("{}: {}", key, value);
9
   }
10
```

Listing 14 - Exemples de déclaration et utilisation d'une HashMap

Pour plus de détails, se référer au chapitre 8 du book [19].

4.1.8 Ownership, Borrowing et références

La caractéristique unique de Rust est sans aucun doute l'*ownership*, ou "possession". L'*ownership* est défini par ces trois règles :

- Chaque variable est dite le "possesseur" (owner) d'une valeur.
- Il ne peut y avoir q'un seul *owner* pour une valeur.
- Lorsque l'owner est détruit ou change de portée, la valeur est détruite.

Avant de continuer sur cette notion, un bref rappel sur l'utilisation de la mémoire est nécessaire. L'OS met à disposition d'un programme deux zones mémoire différentes pour stocker ses variables : la pile (stack) et le tas (heap). Le mécanisme d'accès à la pile est simple et rapide et stocke des variables dont la taille est fixe et connue à la compilation. Les variables de type primitifs (voir paragraphe 4.1.3) sont stockées dans la pile. Lorsqu'une variable dont la taille n'est pas connue à l'avance (type évolué, par exemple les collections) est déclarée, elle placée dans le tas. Un programme voulant stocker une variable sur le tas est obligé de demander à l'OS de chercher un espace disponible assez grand pour stocker la variable et qu'il lui donne un pointeur vers cette zone, pour la retrouver par la suite.

Lorsqu'une valeur est assignée à une variable, elle est détenue par cette variable jusqu'à sa destruction. Le listing 15 illustre un exemple :

```
1  {
2    // my_vec est le "propriétaire" de ce vecteur
3    let my_vec = vec![3, 2, 1];
4    ... // my_vec est utilisé
5  } // la portée de my_vec se termine ici, my_vec est alors supprimé
```

Listing 15 - Portée d'une variable en Rust

La variable my_vec se trouve sur la pile, mais les données vers lesquelles elle pointe se trouvent dans le tas. Lorsque my_vec sera hors de portée, les données dans la pile et dans le tas seront libérées. Si my_vec est assigné à une autre variable, l'ownership des données est transféré à cette nouvelle variable, my_vec ne sera plus accessible et utilisable après l'affectation, comme illustré au listing 16. Ce cas de figure ne se présente pas avec les types primitifs dont la taille en mémoire est connue à la compilation et où une copie des données est effectuée. Pour qu'un type évolué puisse être copié de cette façon, il doit implémenter le trait Copy.

Listing 16 - Transfert de l'ownership en Rust

À la ligne 8 du listing 16, la variable my_vec est invalidée, mais les données vers lesquelles elle pointe. Il n'y a que le pointeur vers ces données qui transféré vers other_vec. C'est ici que la deuxième règle de l'ownership s'applique, il ne peut y avoir plus d'un owner d'une même valeur au même moment. Pour réaliser une vraie copie des données d'un vecteur à un autre, ou de manière générale pour un type évolué, il faut appeler la méthode clone(), qui copie entièrement les données en mémoire. Cette situation de transfert d'ownership survient également lors des appels à des fonctions. Si un paramètre est donné à une fonction, la fonction en prend possession, comme illustré au listing 17.

```
fn main() {
    let mut my_vec = vec![3, 2, 1];
    print_vec(my_vec); // La fonction prend possession du vecteur
    my_vec.push(42); // Erreur, la valeur a été déplacée (move)
}

fn print_vec(v : Vec<i32>) {
    println!("My super vector : {:?}", v);
}
```

Listing 17 - Transfert de l'ownership vers une fonction en Rust

Pour palier à ce problème de transfert de possession lors d'appels aux fonctions, deux solutions existent :

- 1. La fonction doit retourner la valeur possédée. Ce n'est pas pratique si le but de la fonction est de retourner le résultat d'une opération. Elle peut retourner un tuple formé de la ou les valeurs accaparées et du résultat de son opération. Cette manière de faire est lourde et non conseillée.
- 2. La fonction peut "emprunter" la variable de différentes manières (voir ci-dessous).
 Heureusement, les fonctions peuvent se "prêter" les variables par Borrowing ("emprunt").
 Deux types de références aux variables sont disponibles :
 - 1. Les références immutables (syntaxe &ma_variable).
 - 2. Les références mutables (syntaxe &mut ma_variable).

Le listing 18 montre un exemple d'emprunt immutable et mutable.

```
fn main() {
        let mut my_vec = vec![3, 2, 1];
2
        // La fonction emprunte de manière immutable le vecteur
3
        ref_immutable(&my_vec);
        // La fonction emprunte de manière mutable le vecteur
5
        ref_mutable(&mut my_vec);
6
   }
    fn ref_immutable(v : &Vec<i32>) {
        println!("My super vector : {:?}", v);
10
   }
11
12
    fn ref_mutable(v : &mut Vec<i32>) {
13
        v.push(42);
14
    }
15
```

Listing 18 - Emprunts de variables entre fonctions en Rust

Ces références sont proches conceptuellement des pointeurs en C (Rust accepte d'ailleurs le déréférencement des variables avec le symbole *) mais obéissent à deux règles fondamentales :

- 1. À tout moment, il peut y avoir soit une seule référence mutable, soit plusieurs références immutables, mais pas les deux en même temps.
- 2. Les références doivent toujours être valides.

Grâce aux références, Rust évite les problèmes de concurrence sur les valeurs pointées ainsi que les pointeurs invalides. Pour plus de détails, se référer au chapitre 4 du *book* [19]. Il existe également d'autres types de pointeurs, dits "intelligents". Le livre sur Rust dédie un chapitre entier à eux (chapitre 15 du *book* [19]).

4.1.9 Gestion des erreurs

Nonobstant son compilateur très restrictif, détectant à la compilation de nombreuses erreurs, Rust a une gestion avancée des erreurs survenant à l'exécution. Il distingue deux types : les erreurs récupérables et les erreurs irrécupérables (non pas comme dans les langages comme Java ou le concept d'exceptions mélange ces deux types d'erreurs). Pour ces dernières, Rust offre une macro, panic!, stopant abruptement le programme et affichant un message d'erreur sur la sortie standard en indiquant à quelle ligne le programme a planté. Pour les erreurs récupérables, une manière plus élégante existe : à la manière de l'énumération Option vue à la section 4.1.6, l'énumération Result a été conçue pour gérer les erreurs au runtime.

```
enum Result<T, E> {
1
        Ok(T),
2
        Err(E),
3
   }
   fn process(value : Result<u32, std::io::Error>) {
6
        match value {
            Ok(data) => println!("u32 value : {}", data),
            Err(error) => println!("Error : {}", error)
        }
10
   }
11
```

Listing 19 - L'énumération Result et son utilisation avec un pattern matching en Rust

De nombreuses fonctions de la librairie standard et de la communauté retournent des Result, notamment lors de l'ouverture d'un fichier. Comme ce genre d'opérations sont courantes, Rust met à disposition deux fonctions équivalentes à réaliser un match sur un Result, unwrap() et expect(). La seule différence entre les deux est qu'avec la deuxième fonctions, un message personnalisé est attendu en argument. Le listing 20 montre les différentes façons de traiter un Result lors de l'ouverture d'un fichier :

```
fn main() {
        // Version 1
2
        let f = File::open("test.txt");
3
        let f = match f {
            Ok(file) => file,
5
            Err(error) => {
                panic!("Error on opening file : {:?}", error)
            },
        };
        // Version 2
10
        let f = File::open("test.txt").unwrap();
11
        // Version 3
12
        let f = File::open("test.txt").expect("Error on opening test.txt");
13
14
```

Listing 20 - Ouverture d'un fichier et son traitement en Rust

Pour plus de détails, se référer au chapitre 9 du book [19].

4.1.10 Tests

Lorsqu'un nouveau projet *librairie* est créé avec cargo new mylib --lib, un module de tests unitaires est *de facto* ajouté au fichier lib.rs, comme dans le listing 21 :

```
#[cfg(test)]
mod tests {
    #[test]
    fn it_works() {
        assert_eq!(2 + 2, 4);
    }
}
```

Listing 21 – Module de test ajouté automatiquement

Chaque fonction précédée par l'attribut #[test] est considérée par le compilateur comme un test. Pour exécuter les tests, Cargo met à disposition une commande, cargo test. Lorsque cette commande est exécutée, tous les tests sont effectués en parallèle, sans garantir un ordre d'exécution prédéfini. Un résumé des tests effectués, réussis et échoués est affichés sur la sortie standard à la fin de l'exécution de la commande. Pour réaliser nos tests, Rust fournit quelques macros :

- assert! : attend un argument de type bool.
- assert_eq! : attend deux arguments de même type, pour vérifier qu'ils sont égaux.
- assert_ne! : inverse du précédent, vérifie l'inégalité des deux arguments donnés.

Il existe également un autre attribut, #[should_panic], pour réaliser des fonctions qui testent si un morceau de code doit "paniquer", donc échouer. Finalement, la *killer feature* des tests en Rust, c'est que la commande cargo test vérifie également le code donné en exemple dans la documentation de notre code, pour garder une documentation à jour avec notre code. Pour plus de détails, se référer au chapitre 11 du *book* [19].

4.1.11 Concurrence et threads

Pour plus de détails, se référer au chapitre 16 du book [19].

4.1.12 Divers

4.2 Extended attributes

Les extended attributes (XATTR), ou "attributs étendus" en français, sont un moyen d'attacher des méta-données aux fichiers et dossiers sous forme de paires espace:nom:valeur. L'espace de nom, ou namespace en anglais, définit les différentes classes d'attributs. Dans le

cadre de ce projet, l'accent est mis sur le système de fichiers ext4 [23] sous Linux, il existe actuellement quatre espaces de noms ou classes : user, trusted, security et system. L'espace qui nous intéresse est user. C'est là que l'utilisateur ou l'application, pour autant qu'il ait les droits usuels UNIX sur les fichiers, peut manipuler les extended attributes. Les trois autres espaces de noms sont utilisés entre autres pour les listes d'accès ACL (system), les modules de sécurité du kernel (security) ou par root (trusted) [24] [25]. Le nom est une chaine de caractères et la valeur peut être une chaine de caractères ou des données binaires. Les extended attributes sont stockés dans les fichiers. De nombreux FS gèrent leur usage: ext2-3-4, XFS, Btrfs, UFS1-2, NTFS, HFS+, ZFS. Ces FS sont utilisés par les quatre OS les plus répandus : Windows, macOS, Linux et FreeBSD. Windows utilise les extended attributes notamment dans sa gestion des permissions Unix dans le shell Linux intégré à Windows 10 [26]. macOS, comme vu à la section 2.2.2, les utilise entre autres dans son système de gestion des tags. La commande xattr permet de les manipuler. Sous Linux, il en existe trois: attr, getfattr et setfattr. Sous Linux avec ext2-3-4, chaque attribut dispose d'un bloc de données (1024, 2048 ou 4096 bytes) [25]. Apple et freedesktop.org préconisent la notation DNS inversée pour nommer les attributs [27], [28] car n'importe quel processus peut modifier les attributs dans l'espace utilisateur. En préfixant du nom du programme le nom de l'attribut, par exemple user.myprogram.myattribute, on diminue le risque qu'une autre application utilise le même nom d'attribut. Malheureusement, la plupart des outils CLI Linux pour manipuler les fichiers comme cp, tar, etc. ne prennent pas en compte les attributs avec leur syntaxe par défaut [29].

4.2.1 Petites manipulations

Pour vérifier la portabilité des XATTR, quelques tests ont été réalisés entre un SSD faisant office de disque système à Linux Mint avec 2 clés USB (de 8 et 64 Go) et un emplacement réseau monté en NFS. Le listing suivant montre la sortie de la commande df, qui renvoie l'utilisation des différents emplacements de stockage, dans l'ordre : le disque système, en ext4, la clé de 8 Go formatée une fois en FAT32, puis une autre fois en NTFS, la clé de 64 Go formatée en ext4 et finalement une machine virtuelle sous Debian 9 montée en NFS.

1	Sys. de fichiers	Туре	Taille	Utilisé	Dispo	Uti%	Monté sur
2	/dev/sda2	ext4	451G	334G	96G	78%	/
3	/dev/sdg1	vfat	7.7G	4.0K	7.7G	1%	/media/pc/cle1
4	/dev/sdg1 /dev/sdg1	fuseblk	7.7G	41M	7.7G	1%	/media/pc/cle1
5	/dev/sdg1	ext4	59G	33G	23G	59%	/media/pc/cle2
6	192.168.1.21:/home/user	nfs4	916G	198G	673G	23%	/mnt/debian

Listing 22 - Output de df -Th : le disque système, les clés USB et le NFS

La démarche est la suivante : un XATTR dans l'espace user avec comme nom author et

comme valeur steven est ajouté au fichier file.txt avec attr. Ce fichier est copié avec cp en prenant garde à préserver l'attribut (option --preserve=xattr). Une fois copié, on tente de lire le même attribut, toujours avec attr. Les résultats sont les suivants :

```
~ $ attr -s author -V steven file.txt
L'attribut "author" positionné à une valeur de 6 octets pour file.txt :
steven

~ $ cp --preserve=xattr file.txt /media/pc/cle1
cp: setting attributes for '/media/pc/cle1/file.txt': Opération non supportée
```

Listing 23 – Copie sur clé USB 8 Go, FAT32

```
~ $ attr -s author -V steven file.txt
L'attribut "author" positionné à une valeur de 6 octets pour file.txtă:
steven

~ $ cp --preserve=xattr file.txt /media/pc/cle1

~ $ cd /media/pc/cle1

/media/pc/cle1 $ attr -g author file.txt
L'attribut "author" avait une valeur de 6 octets pour file.txtä:
steven
```

Listing 24 – Copie sur clé USB 8 Go, NTFS

```
66  ~ $ attr -s author -V steven file.txt
67  L'attribut "author" positionné à une valeur de 6 octets pour file.txtă:
68  steven
69  ~ $ cp --preserve=xattr file.txt /media/pc/cle2
70  ~ $ cd /media/pc/cle2
71  /media/pc/cle2 $ attr -g author file.txt
72  L'attribut "author" avait une valeur de 6 octets pour file.txtă:
73  steven
```

Listing 25 - Copie sur clé USB 64 Go, ext4

```
78 ~ $ cp --preserve=xattr file.txt /mnt/debian
79 cp: setting attributes for '/mnt/debian/file.txt': Opération non
supportée
```

Listing 26 - Copie sur l'emplacement réseau distant, NFS

On constate que l'opération est infructueuse sur la clé en FAT32 et sur l'emplacement réseau monté en NFS alors qu'elle réussit sur les clés USB en NTFS et ext4.

Deux autres petites expériences ont été menées avec la commande mv et la copie/déplacement de fichiers avec l'explorateur de fichiers Nemo de Linux Mint. Ces deux opérations conservent par défaut les XATTR.

4.3 inotify

Sous Linux, un outil (inclu au noyau) dédié à la surveillance du FS existe, inotify [30]. Comme son nom l'indique, inotify donne la possibilité à une application d'être notifiée sur des événements au niveau du système de fichiers. Une API en C existe et offre les SYSCALL suivants :

- 1. int inotify_init(void): initialise une instance inotify et retourne un descripteur de fichier.
- 2. int inotify_add_watch(int fd, const char *pathname, uint32_t mask): cette fonction attend le descripteur de fichier renvoyé par inotify_init, un chemin de fichier ou répertoire à surveiller et un masque binaire constitué des événements à surveiller (voir plus loin). Il retourne un nouveau descripteur de fichier qui pourra être lu avec le SYSCALL read().
- 3. int inotify_rm_watch(int fd, int wd) : appel inverse du précédent, supprime la surveillance du descripteur de fichier wd de l'instance inotify retournée par fd.

inotify s'utilise comme suit : il faut initialiser l'instance (1), ajouter les fichiers et répertoires pour la surveillance avec le masque des événements voulus (2) et, généralement, dans une boucle, appeler le SYSCALL read() avec comme argument le descripteur de fichier renvoyé par inotify_init(). Chaque appel abouti à read() retourne la structure suivante :

```
struct inotify_event {
1
                           /* Descripteur de surveillance */
       int
                wd;
2
                           /* Masque d'événements */
       uint32_t mask;
                           /* Cookie unique d'association des
       uint32_t cookie;
4
                              événements (pour rename(2)) */
5
       uint32_t len;
                           /* Taille du champ name */
6
                           /* Nom optionnel terminé par un nul */
       char
                name[];
7
   };
```

Listing 27 - Structure inotify_event - [30]

Le champ mask peut prendre les valeurs suivantes (multiples valeurs autorisées, séparées par des "ou" logiques -> "|") :

- IN ACCESS : accès au fichier.
- IN ATTRIB : changement sur les attributs du fichier.
- IN_CLOSE_WRITE : fichier ouvert en écriture fermé.
- IN CLOSE NOWRITE : fichier ouvert en écriture fermé.
- IN CREATE : création de fichier/répertoire.
- IN DELETE : suppression d'un fichier/répertoire.
- IN DELETE SELF : suppression du répertoire surveillé lui-même.
- IN MODIFY : modification d'un fichier/répertoire.
- IN MOVE SELF : suppression d'un fichier/répertoire.
- IN MOVE FROM : déplacement/renommage du répertoire (ancien nom).
- IN_MOVE_TO : déplacement/renommage du répertoire (nouveau nom).
- IN OPEN : ouverture d'un fichier.
- IN_ALL_EVENTS : macro combinant tous les événements précédents.

Le champ cookie de la structure inotify_event prend tout son sens lors des événements IN_MOVE : un numéro unique est généré pour faire le lien entre ces deux sous-événements, qui ne sont en réalité qu'un seul. inotify offre donc une très bonne base pour la surveillance du FS. Il possède cependant quelques limitations :

- Pas de surveillance récursive d'un répertoire : si une arborescence complète doit être surveillée, il faut pour chaque sous-répertoire ajouter une surveillance dédiée.
- Les chemins de fichiers peuvent changer entre l'émission d'un événement et son traitement.
- inotify ne permet que la surveillance de répertoires en espace utilisateur par défaut.
- Il n'y pas de moyen de discriminer quel processus ou utilisateur a généré un événement.

Il existe plusieurs outils système qui utilisent inotify [31] :

- incron : équivalent de cron, mais l'exécution des tâches se fait non pas selon un horaire donné, mais selon un événement donné sur un fichier.
- 1syncd : outil de synchronisation, basé sur rsync. La synchronisation est effectuée à chaque changement dans le répertoire surveillé vers une liste d'emplacements distants configurés à l'avance.
- iwatch : déclenchement d'une commande selon un événement inotify.
- inotify-tools : deux commandes permettant d'utiliser inotify directement dans le terminal :
 - inotifywait : exécute une attente sur un événement, avant de continuer le fil d'exécution.

— inotifywatch : retourne une liste d'événements des répertoires surveillés.

Pour plus d'informations, la page de man sur inotify existe [30] et un très bon article en deux parties sur les ajouts de inotify par rapport à dnotify (son prédécesseur) [32] et sur ses limitations par Michael Kerrisk [33].

4.4 Sockets

5 Réalisation

5.1 Tag Manager

La première réalisation de ce projet est un outil en ligne de commande, écrit en Rust, permettant de facilement lister, ajouter et supprimer des tags à des fichiers et dossiers. Il fait usage de deux *crates* disponibles sur crates.io : clap [34] et xattr [35]. Clap (Command Line Argument Parser for Rust) est une librairie pour parser les arguments d'un programme en ligne de commande. Xattr est une API en Rust pour récupérer, lister, ajouter/modifier et supprimer des XATTR avec Rust. Elle utilise les SYSCALL en C fournis par Linux.

5.2 Tag Engine

[36]

- 6 Protocole de test
- 6.1 Benchmarks
- 6.2 Mesure de performances

7 Discussion/résultats

8 Conclusion

9 Références

- [1] Jean-Francois Dockes. Extended attributes and tag file systems. https://www.lesbonscomptes.com/pages/tagfs.html, juillet 2015. Consulté le 04.05.2018.
- [2] Paul Ruane alias oniony. Tmsu. https://tmsu.org/. Consulté le 18.05.2018.
- [3] Tagsistant. Tagsistant: semantic filesystem for linux. http://www.tagsistant.net/. Consulté le 18.05.2018.
- [4] Tagsistant. Tagsistant 0.8.1 howto. http://www.tagsistant.net/documents-about-tagsistant/0-8-1-howto, mars 2017. Consulté le 18.05.2018.
- [5] Andrei Marukovich. Taggedfrog quick start manual. http://lunarfrog.com/projects/taggedfrog/quickstart. Consulté le 18.05.2018.
- [6] TagSpaces. Your offline data manager. https://www.tagspaces.org/. Consulté le 18.05.2018.
- [7] TagSpaces. Organize your data with tags. https://docs.tagspaces.org/tagging. Consulté le 18.05.2018.
- [8] Greg windows fol-Shultz. An in-depth look vista's virtual at ders technology. https://www.techrepublic.com/article/ an-in-depth-look-at-windows-vistas-virtual-folders-technology/, OCtobre 2005. Consulté le 21.05.2018.
- [9] Russell Smith. Manage documents with windows explorer using tags and file properties. https://www.petri.com/manage-documents-with-windows-explorer-using-tags-and-file-properties, avril 2015. Consulté le 21.05.2018.
- [10] Apple team. Os x : Tags help you organize your files. https://support.apple.com/en-us/HT202754, février 2015. Consulté le 08.05.2018.
- [11] John Siracusa. Mac os x 10.4 tiger spotlight. https://arstechnica.com/gadgets/2005/04/macosx-10-4/9/, avril 2005. Consulté le 08.05.2018.
- [12] John Siracusa. Os x 10.9 mavericks: The ars technica review tags. https://arstechnica.com/gadgets/2013/10/os-x-10-9/8/, octobre 2013. Consulté le 08.05.2018.
- [13] John Siracusa. Os x 10.9 mavericks: The ars technica review tags implementation. https://arstechnica.com/gadgets/2013/10/os-x-10-9/9/, octobre 2013. Consulté le 08.05.2018.
- [14] John Siracusa. Mac os x 10.5 leopard : the ars technica review fsevents. https://arstechnica.com/gadgets/2007/10/mac-os-x-10-5/7/, octobre 2007. Consulté le 08.05.2018.

- [15] Wikipédia. Un annuaire représenté comme une table de hachage. https://fr. wikipedia.org/wiki/Table_de_hachage#/media/File:HASHTB08.svg, juin 2015. Consulté le 23.06.2018.
- [16] Jean-François Hêche. Graphes & Réseaux. février 2012. Consulté le 13.06.2018.
- [17] The Rust communitys crate registry. https://crates.io/. Consulté le 05.05.2018.
- [18] r/rust. https://www.reddit.com/r/rust/. Consulté le 05.05.2018.
- [19] Rust Team. The rust programming language, 2nd edition. https://doc.rust-lang.org/stable/book/second-edition/. Consulté le 25.04.2018.
- [20] Computational Geometry Lab. Learning rust with entirely too many linked lists. http://cglab.ca/~abeinges/blah/too-many-lists/book/. Consulté le 28.04.2018.
- [21] Manuel Hoffmann. Are we (i)de yet? https://areweideyet.com/. Consulté le 25.04.2018.
- [22] The Cargo Book. https://doc.rust-lang.org/cargo/. Consulté le 05.05.2018.
- [23] Wikipedia. ext4. https://en.wikipedia.org/wiki/Ext4, mai 2018. Consulté le 18.06.2018.
- [24] Jeffrey B. Layton. Extended file attributes rock! http://www.linux-mag.com/id/8741/, juin 2011. Consulté le 09.05.2018.
- [25] Andreas Gruenbacher. attr(5) linux man page. https://linux.die.net/man/5/attr. Consulté le 09.05.2018.
- [26] Jack Hammons. Wsl file system support. https://blogs.msdn.microsoft.com/wsl/2016/06/15/wsl-file-system-support/, juin 2016. Consulté le 21.05.2018.
- [27] John Siracusa. Mac os x 10.4 tiger extended attributes. https://arstechnica.com/gadgets/2005/04/macosx-10-4/7/, avril 2005. Consulté le 08.05.2018.
- [28] freedesktop.org. Guidelines for extended attributes. https://www.freedesktop.org/wiki/CommonExtendedAttributes/, mai 2018. Consulté le 04.05.2018.
- [29] Jean-Francois Dockes. Extended attributes: the good, the not so good, the bad. https://www.lesbonscomptes.com/pages/extattrs.html, juillet 2014. Consulté le 04.05.2018.
- [30] inotify monitoring filesystem events. http://man7.org/linux/man-pages/man7/inotify.7.html, septembre 2017. Consulté le 13.06.2018.
- [31] Denis Dordoigne. Exploiter inotify, cest simple. https://linuxfr.org/news/exploiter-inotify-c-est-simple, novembre 2014. Consulté le 13.06.2018.
- [32] Michael Kerrisk. Filesystem notification, part 1 : An overview of dnotify and inotify. https://lwn.net/Articles/604686/, juillet 2014. Consulté le 13.06.2018.
- [33] Michael Kerrisk. Filesystem notification, part 2 : A deeper investigation of inotify. https://lwn.net/Articles/605128/, juillet 2014. Consulté le 13.06.2018.

- [34] Kevin Knapp. clap. https://crates.io/crates/clap, mars 2018. Consulté le 14.05.2018.
- [35] Steven Allen. xattr. https://crates.io/crates/xattr, juillet 2017. Consulté le 14.05.2018.
- [36] Nick Cameron. Graphs and arena allocation. https://aminb.gitbooks.io/rust-for-c/content/graphs/index.html, juin 2015. Consulté le 08.06.2018.